

Логика работы SoftInform Search Server

1. Технические характеристики

SoftInform Search Server позволяет проводить индексирование более 100 типов файлов, при индексации данных используются возможности морфологии и синонимии.

Характеристика	Значение
Скорость индексирования текста ¹	1 – 30 ГБ/час
Обрабатываемые форматы (поддерживается более 100 типов файлов)	Файлы MS Office: DOC, DOCX, DOT, XLS, XLSB, XLSX, XLSM, XLT, XLTX, XLTM, PPT, PPTX, RTF Базы данных: MDB Файлы Internet: HTM, HTML, SHTML, CSS, JS, MAFF Электронные сообщения: MSG, EML Программные файлы MS Windows: TXT, CSV, PDF, DJVU, XML, LST, CHM, BAT, LOG, INI, WRI, MHT, HLP Архивы и сжатые файлы: 7Z, ARJ, RAR, ZIP, JAR, TAR, ISO, GZ, GZIP, TGZ, TPZ, CAB, LZH, LHA, Z, TAZ, LZMA, BZ2, BZIP2, TBZ2, TBZ, HFS Файлы языков программирования: JAVA, PAS, DFM, DPR, BAS, CPP, HPP, C, C++, H, CS, SQL, JSP, ASP, ASPX, PHP, WSDL, PY, PL, INC, VB, VBS, XLA, CMD Файлы PowerBuilder: SRA, SRJ, SRW, SRU, SRM, SRS, SRF, SRD, SRQ, SRP Аудио/видео файлы: MP3, AVI Файлы OpenOffice: SXW, STW, ODT, ODS Графические форматы: JPG, JPEG, TIF, TIFF, BMP, PNG, GIF Старые текстовые форматы: LEX, ASC

¹ Зависит от типов файлов. Скорость индексирования падает при включенном распознавании текста в графических документах. Распознавание одного графического документа обычно занимает 0,5 – 10,0 с.

Характеристика	Значение
Обновление индекса	Инкрементальное. Индексируются только документы, перехваченные с момента предыдущего индексирования.
Объем индекса	10 – 25% размера проиндексированных файлов, но не менее 65 MB.

2. Алгоритм работы

Возможные алгоритмы работы Search Server (в зависимости от типов файлов):

- docs2text.exe -> etextffile.exe -> Adobe iFilter
- docs2text.exe -> Adobe iFilter (используется только в 32-х разрядных системах)
- docs2text.exe -> TextLib
- siocr.exe (используется при индексировании изображений)

2.1 Процесс docs2text

Процесс «docs2text.exe» позволяет извлекать текст из офисных документов (DOC, DOCX, DOT, XLS, XLSB, XLSX, XLSM и др.) и PDF с помощью пакета Adobe iFilter (x32). Для 64-разрядных систем вызывается процесс «etextffile.exe», работающий с iFilter (x64).

Также процесс «docs2text.exe» при необходимости вызывает библиотеку TextLib, используемую для извлечения текста из файлов различных форматов.

2.2 Процесс etextffile

Процесс «etextffile.exe» позволяет извлекать текст из офисных документов (DOC, DOCX, DOT, XLS, XLSB, XLSX, XLSM и др.) и PDF с помощью пакета iFilter (x64).

2.3 Процесс siocr

Для работы с OCR используется модуль NicomSoft OCR.

Search Server вызывает процесс «siocr.exe» для извлечения текста из изображений методом OCR. PDF-файлы, состоящие из изображений, так же конвертируются в текст посредством «siocr.exe».

2.4 Библиотеки TextLib

Сторонние библиотеки TextLib (<http://textlib.com>) используются для извлечения текста из файлов офисных форматов (DOC, DOCX, DOT, XLS, XLSB, XLSX, XLSM и др.) и PDF. Вызов библиотек производит процесс «docs2text.exe».

2.5 Adobe iFilter

Пакет Adobe iFilter используется для извлечения текста из офисных документов и PDF. Для каждой разрядности операционной системы должен быть установлен соответствующий пакет (x32/x64).

2.6 Количество процессов

Число процессов «docs2text.exe» равняется двум на одну индексацию. Однако количество процессов может быть большим. Например, если извлечение текста из файла продолжается дольше заданного значения таймаута (файл большого объема), то Search Server оставляет текущий и переходит к следующему документу (запуская новый процесс), а текущий процесс продолжает работать до тех пор, пока не закончит извлечение текста. Временем жизни процессов управляет Windows, т.к. это COM-объекты.

Значение таймаута по умолчанию 60 сек. Значение можно изменить в файле tsearch.ini, параметр «TextExtractTimeOut».

Таймаут на извлечение картинок из PDF и максимальное время на оцифровку изображений задается в консоли Search Server.